

董浩森

算法工程师 • Agentic RL

安徽合肥 • 随时到岗 • 男 • 22 岁 • 本科 • 1 年经验

15623287592 • haosendong2004@gmail.com



教育背景

武汉大学 (985、211) 计算机学院 / 计算机科学与技术 • GPA 3.91/4.00 (Top 3%) • 武汉
• 国家奖学金、甲等奖学金、乙等奖学金、金山助学金、; 三项国家发明专利, 8 项竞赛获奖, 一篇 CV 领域 SCI 论文。 2022.09 – 2026.06

中国科学技术大学 (985、211) 计算机学院 / 电子信息 • 合肥 2026.09 – 预计入学

实习经历

字节跳动 • 抖音直播部门 2026.06 – 至今

大模型算法实习生 北京

多模态 4D 拆件模型训练: 负责多模态结构化生成模型的数据与训练链路, 完成 GLB 清洗去重、多视图渲染、部件 Tree/Schema、层级关系、3D BBox 及 CoT 生成, 构造 17 万条训练数据; 基于 SeedLite 开展有/无 CoT 的 LoRA 实验, 并在 Qwen3.6-35B-A3B 上进行全量 SFT, 分析训推输入分布差异与 2D 图像到 3D Grounding 的能力瓶颈。

3D 模组质量奖励模型训练: 面向悬浮断连、几何渲染、穿插嵌入及比例姿态四类质量问题, 构建 1299 个模组、5196 条正负均衡的专项 SFT 数据, 并生成有/无 CoT 两个版本; 通过 GPT 评审能力蒸馏、LoRA 及全量 SFT 对比实验, 建立分维度准确率、正负样本召回率与混淆矩阵评测, 定位奖励投机、正样本偏置及推理过长等问题。

RL/DPO 奖励信号与质量评测体系: 负责 3D 生成模组的奖励信号设计与 DPO 数据过滤, 搭建融合八视图渲染和 Three.js 源码证据的 LLM-as-Judge 管线, 覆盖 Prompt 一致性、结构完整性、功能拓扑及穿模错误; 完成评测 Prompt 从 V1 至 V4 的迭代, 引入父子 Transform、运动净空、视觉容差和文字专项规则, 提升 Bad Case 识别能力与奖励结果的人类偏好一致性。

中国电信人工智能研究院 (TeleAI) 2025.08 – 2026.06

VLM 算法实习生 • 视觉理解研发中心 上海

TeleMM-2.0-Thinking 模型训练: 参与星辰多模态大模型 TeleMM-2.0-Thinking 视觉语言模型的 RL 训练, 协助模型迭代 8 个版本。模型提交时在 OpenCompass 多模态榜单中, 通用类得分 81.2、排名第二 (高于 Gemini 2.5 Pro), 推理类排名第五 (高于豆包 1.5 Pro)。

- **训练支持:** 实现并改进 verl 对 TeleMM 的 RLVR 训练支持; 参与 TeleMM 的 ms-swift RLHF 训练支持和 VLMEvalKit 测评。
- **数据构建:** 构建系统化数据 pipeline, 筛选 10 万条可验证数据用于 RLVR 训练。
- **RL 训练:** 参与模型 RL 训练全流程, 探索 DAPO、SPO、DPO 等多种训练方案和多阶段训练。

Location-depends-on-guessing 视觉语言模型训练: 参与模型训练, 负责基于 GRPO 的 grounding 能力提升代码实现与训练, 获得 MARS2 2025 现实场景视觉定位 (VG-RS) 挑战赛第三名。

Vision Encoder 大规模训练数据构建: 针对 DenseFusion-1M 和 LLaVA91M 构建细粒度标注图文对: 通过长 caption 抽取 referring expressions, 再用 YOLO-World 自动 grounding 得到区域 bbox, 并生成对应的 short_expr、long_expr 和 hard negatives。数据用于细粒度图文对比学习, 使模型学习整图—文本、局部区域—文本之间的对齐关系。

面向长程复杂任务的 Agent 训练: 负责将 ALFWorld、WebShop、SCIWorld、Sokoban、APPWorld、AndroidWorld、QwenClawBench、PawBench、SkillsBench 集成到 slime 训练框架; 提出 DEPPPO, 通过成功/失败双经验池与经验引导的优势重加权, 在无需 Critic 或过程监督的情况下实现 step-level 信用分配。

科研成果 (均为第一作者)

- **DEPPO: 基于双经验池的长程强化学习方法。** 针对稀疏终局奖励下轨迹级监督难以进行逐步信用分配的问题, 提出无 Critic、经验驱动的 DEPPO; 构建成功/失败双经验池, 通过同一任务—状态下动作在两池中的相对似然自适应重标优势, 并以新颖性感知插入、衰减与剪枝动态更新经验。在 Qwen2.5-7B 上, ALFWorld 平均成功率达 95.7, WebShop Score/Success 达 90.1/84.3, 较 GIGPO 分别提升 7.1 和 9.1 个百分点, 并在 Sokoban 上稳定优于 GRPO/GIGPO。论文投稿至 **EMNLP 2026 (OA: 3.5, Meta: 3.5)**。
- **SVO: 多模态大模型推理训练强化学习框架。** 针对传统 RLVR 仅依赖最终答案奖励而导致推理过程与答案不一致的问题进行改进, 缓解 shortcut reasoning。在多个数学推理任务上, 相较 GRPO、DAPO 和 SOTA RLVR 训练方法, 推理—答案一致性提升约 20%, 一致性约束准确率提升约 8%, 并保持同等或更高的准确率水平。论文投稿至 **EMNLP 2026 (OA: 3.33, Meta: 3)**。
- **SkillID: 面向多步 LLM Agent 的难度感知技能对比强化学习方法。** 根据任务成功率划分难、中、易任务, 自适应使用外部 Skill 指导探索, 并通过技能条件与无技能策略的对比优势加权识别受 Skill 影响的关键步骤; 旨在缓解稀疏延迟奖励下的长程探索困难, 提升训练稳定性、样本效率与泛化能力。论文投稿至 **AAAI 2027**。
- **SkillIG: 稀疏奖励环境下的外部技能内化方法。** 针对智能体依赖外部技能提示、难以实现无技能执行的问题, 通过比较同一动作在有技能与无技能上下文下的对数概率, 实现 step-level 信用分配; 采用技能预热、依赖感知课程学习 (动态调整使用 Skill 的任务比率) 和无技能冷却三阶段训练策略, 实现 Skill 内化。论文预投稿至 **AAAI 2027**。